



INF330

Inteligencia de Negocios

Profesor Mauricio Figueroa Colarte

Segundo Semestre 2026



ESTAMOS POR EMPEZAR



UNIVERSIDAD TECNICA
FEDERICO SANTA MARIA



Departamento de Informática
Universidad Técnica Federico Santa María



INF330

Inteligencia de Negocios

Profesor Mauricio Figueroa Colarte

Segundo Semestre 2026



UNIVERSIDAD TECNICA
FEDERICO SANTA MARIA



Departamento de Informática
Universidad Técnica Federico Santa María

Hoy en Inteligencia de Negocios


-  Definición del Proceso de Extracción, Transformación y Carga (ETL)
-  Fases del Proceso de Extracción, Transformación y Carga (ETL)

Proceso de ETL

Introducción


Los procesos de **ETL** (Extracción, Transformación y Carga), son los encargados, principalmente, de actualizar la información desde los sistemas fuentes (source) hacia el Data Warehouse, y también entre los subsistemas que componen la arquitectura de un sistema de Inteligencia de Negocios (BI).

Los procesos de ETL deberán ejecutarse periódicamente, normalmente en las noches, para sincronizar al contenido entre los diversos sistemas.




Introducción

Los procesos de ETL son relevantes en la integración de los diferentes componentes de la Arquitectura de Inteligencia de Negocios (BI).




Introducción

Los procesos de ETL son relevantes en la integración de los diferentes componentes de la Arquitectura de Inteligencia de Negocios (BI).




Introducción

Los procesos de ETL son relevantes en la integración de los diferentes componentes de la Arquitectura de Inteligencia de Negocios (BI).




Introducción

Los procesos de ETL son relevantes en la integración de los diferentes componentes de la Arquitectura de Inteligencia de Negocios (BI).




Introducción

Los procesos de ETL son relevantes en la integración de los diferentes componentes de la Arquitectura de Inteligencia de Negocios (BI).




Introducción

Los procesos de ETL son relevantes en la integración de los diferentes componentes de la Arquitectura de Inteligencia de Negocios (BI).



Introducción

Los procesos de ETL son relevantes en la integración de los diferentes componentes de la Arquitectura de Inteligencia de Negocios (BI).



Consideraciones

Los procesos de ETL deben ser diseñados tanto para la carga inicial del Data Warehouse (carga full) como para la carga periódica (carga incremental), considerando el menor impacto en los sistemas fuentes y teniendo presente los siguientes puntos:



Consideraciones

Los procesos de ETL deben ser diseñados tanto para la carga inicial del Data Warehouse (carga full) como para la carga periódica (carga incremental), considerando el menor impacto en los sistemas fuentes y teniendo presente los siguientes puntos:



Consideraciones

Los procesos de ETL deben ser diseñados tanto para la carga inicial del Data Warehouse (carga full) como para la carga periódica (carga incremental), considerando el menor impacto en los sistemas fuentes y teniendo presente los siguientes puntos:




Consideraciones

Los procesos de ETL deben ser diseñados tanto para la carga inicial del Data Warehouse (carga full) como para la carga periódica (carga incremental), considerando el menor impacto en los sistemas fuentes y teniendo presente los siguientes puntos:



Consideraciones

Los procesos de ETL deben ser diseñados tanto para la carga inicial del Data Warehouse (carga full) como para la carga periódica (carga incremental), considerando el menor impacto en los sistemas fuentes y teniendo presente los siguientes puntos:



Consideraciones

Los procesos de ETL deben ser diseñados tanto para la carga inicial del Data Warehouse (carga full) como para la carga periódica (carga incremental), considerando el menor impacto en los sistemas fuentes y teniendo presente los siguientes puntos:



Consideraciones

Los procesos de ETL deben ser diseñados tanto para la carga inicial del Data Warehouse (carga full) como para la carga periódica (carga incremental), considerando el menor impacto en los sistemas fuentes y teniendo presente los siguientes puntos:



Consideraciones

Los procesos de ETL deben ser diseñados tanto para la carga inicial del Data Warehouse (carga full) como para la carga periódica (carga incremental), considerando el menor impacto en los sistemas fuentes y teniendo presente los siguientes puntos:



Consideraciones

GIGO : Garbage in = Garbage out

Si tus datos son de mala calidad...

... no esperes resultados de buena calidad



<https://getgareth.github.io/2016/12/27/Garbage-in,-garbage-out.-A-developer-story.html>

Consideraciones

Calidad de Datos: Hemos dicho que la calidad de los datos es clave para obtener buenos resultados en todo el proceso de Inteligencia de Negocios, por lo que, necesita de mayor atención. Para ello se sugiere considerar las siguientes reglas:

UNIQUENESS


- Existence of unique values for a specific data attribute within a table
- **Example:** Data attribute which has duplicated values will not have the highest score on uniqueness dimension

CONSISTENCY

- Logical coherence within data of a system that free them from contradiction
- **Example:** 'Order Fulfilment Date' should be after the 'Order Creation Date'

INTEGRITY

- Existence of data values in reference table(s) from different system(s)
- **Example:** 'Product ID' values should exist in the Product reference table



COMPLETENESS

- Existence of values in a specific data attribute (data field)
- **Example:** Data attribute with missing values is not complete

TIMELINESS

- Degree to which data is representative of current business conditions (updated and available)
- **Example:** A plan price change not updated on the day it was issued creates a breach of timeliness

CONFORMITY

- Data are valid if it conforms to the syntax (format, type, range) of its definition
- **Example:** 'Landline Number' should be numeric with 8 digits

Fuente : <https://www.deltapartnersgroup.com/managing-data-quality-optimize-value-extraction>


i1 Cosa !

¿Qué es importante recordar
sobre el proceso ETL?


PREGUNTAS

Fases del Proceso de ETL


Fases de ETL




Fases de ETL



Fases de ETL




Fases de ETL



Fases de ETL

Extracción: Antes de llevarla a cabo, hay que identificar los cambios, al determinar los datos operacionales (relevantes) que han sufrido una modificación desde el último refresh.

Si los datos están en un DBMS, la extracción de datos se puede reducir a consultas en SQL, sin embargo, si los datos están en un sistema propietario (no se conoce el formato de los datos) o en fuentes externas textuales, hipertextuales u hojas de cálculo, la extracción puede ser más difícil y puede tener que realizarse a partir de informes o volcados de datos proporcionados por los usuarios. Este caso puede ser más complejo desde el punto de vista de la automatización y de la calidad de datos.



Fases de ETL

Extracción : Para identificar los cambios que se generan en los sistemas fuentes y que deben llevarse al Data Warehouse, existen diversos métodos:

Carga total

Comparación a nivel de base de datos (tablas)

Comparación de nivel de archivos (Día N con día N-1)

Uso de marcas de tiempo (time stamping) en los registros del sistema operacional


Uso de disparadores (triggers) en el sistema operacional

Uso del archivo de log (gestión de transacciones) del sistema operacional

Uso de técnicas mixtas

Fases de ETL

Transformación : Los datos que son extraídos desde las distintas fuentes pueden requerir algunas transformaciones, ya sea, por requerimientos específicos del negocio y/o porque vienen con “impurezas” o anomalías.



Fases de ETL

Transformación : La calidad de los datos es determinante en el éxito del modelo de Inteligencia de Negocios resultante, por lo que, es necesario tener presente lo siguiente :

Tipos de anomalías

- Datos con ruido, registros duplicados, outliers, datos inconsistentes, datos faltantes o “missing values”.

Tipos de Transformaciones

- Limpieza, formateo, integración

La transformación de datos genera “datos de calidad”

- Conducen a patrones/reglas de calidad. Esto se logra a través de:
 - Recuperación de información perdida.
 - Eliminación de outliers.
 - Resolución de conflictos.

Fases de ETL

Transformación : Se requiere de una limpieza de datos (cleansing) que permita llenar valores perdidos, suavizar datos con ruido, identificar outliers y corregir datos inconsistentes.

Eliminar o reemplazar la columna

- Solución extrema, pero a veces existe otra columna dependiente con datos de mayor calidad. Preferible a eliminar la columna es reemplazarla por una columna booleana diciendo si el valor existía o no.

Acciones posibles

Eliminar la fila

- Algunos valores faltantes expresan características relevantes: por ejemplo, la ausencia de un número de teléfono puede representar el deseo de que no se moleste a la persona en cuestión.
- Valores no existentes: algunos valores faltantes pueden no existir en la realidad. Un cliente que acaba de regresar al negocio no tiene consumo medio de los últimos 12 meses.



Fases de ETL

Transformación : Se requiere de una limpieza de datos (cleansing) que permita llenar valores perdidos, suavizar datos con ruido, identificar outliers y corregir datos inconsistentes.

Reemplazar valores

Acciones posibles

- Por una constante (unknown), por el promedio u otro valor que a veces se puede predecir, por ejemplo con una Regresión Lineal.




Fases de ETL

Transformación : Para determinar el “estado de salud” de nuestros datos para posteriormente tomar decisiones respecto de qué transformaciones debemos aplicar, es muy útil contar con alguna herramienta para Análisis Exploratorio de Datos, como por ejemplo *fg-data-profiling* para explorar los datos y/o *Julius.ai* para refinarlos.



[fg-data-profiling](#)
EDA for Python




<https://julius.ai/>

Fases de ETL

Transformación

Ejemplo 1 : Desde un set de datos de postulaciones a una universidad, *Pandas Profiling* pudo detectar valores faltantes en las columnas Longitud, Latitud y PACE (Programa de Acceso a la Educación Superior). Consultando al negocio, se decidió eliminar las columnas Longitud y Latitud por no ser relevantes para el problema y la columna PACE si es relevante , por lo que se decidió completar los valores faltantes por “Sin PACE”.

FACULTAD	PUNTAJE	GRUPO_DEPEN	REGION	LATITUD	LONGITUD	RTJE_NEM	PSU_PROMLM	PACE	GRATUIDAD	MATRICULADO
CIENCIAS RELIGIOSAS Y FILOSOFICAS	50740	MUNICIPAL	MAULE			431	5155	NO	NO	
CIENCIAS RELIGIOSAS Y FILOSOFICAS	50320	MUNICIPAL	LIBERTADOR GENERAL BERNARDO O'HIGGINS			445	5320	NO	NO	
CIENCIAS DE LA SALUD	61110	MUNICIPAL	MAULE			620	5510	NO	NO	
CIENCIAS DE LA SALUD	65585	PARTICULAR SUBVENCIONADO	MAULE			672	5940	PACE	SI	SI
CIENCIAS DE LA SALUD	60950	MUNICIPAL	LIBERTADOR GENERAL BERNARDO O'HIGGINS			672	4775	NO	NO	
CIENCIAS DE LA SALUD	69335	MUNICIPAL	REGIÓN METROPOLITANA DE SANTIAGO			775	5715	NO	NO	
CIENCIAS DE LA SALUD	62080	PARTICULAR SUBVENCIONADO	MAULE			688	5530	NO	NO	
CIENCIAS DE LA SALUD	62110	MUNICIPAL	MAULE			637	5420	NO	NO	
CIENCIAS DE LA SALUD	61310	MUNICIPAL	MAULE			657	5635	NO	NO	
CIENCIAS DE LA SALUD	62065	PARTICULAR PAGADO	LIBERTADOR GENERAL BERNARDO O'HIGGINS			605	6490	NO	NO	
CIENCIAS RELIGIOSAS Y FILOSOFICAS	50230	MUNICIPAL	MAULE			461	5110	SI	SI	
CIENCIAS DE LA SALUD	61600	PARTICULAR SUBVENCIONADO	MAULE			605	5775	NO	NO	
CIENCIAS RELIGIOSAS Y FILOSOFICAS	56645	MUNICIPAL	LIBERTADOR GENERAL BERNARDO O'HIGGINS			558	5750	NO	NO	
CIENCIAS RELIGIOSAS Y FILOSOFICAS	60560	MUNICIPAL	MAULE			642	5395	SI	SI	
CIENCIAS DE LA SALUD	62470	MUNICIPAL	BÍO-BÍO			641	5770	NO	NO	
CIENCIAS RELIGIOSAS Y FILOSOFICAS	55145	PARTICULAR SUBVENCIONADO	MAULE			566	5105	NO	NO	
CIENCIAS DE LA SALUD	63310	PARTICULAR SUBVENCIONADO	BÍO-BÍO			713	5245	SI	SI	
CIENCIAS DE LA SALUD	61350	MUNICIPAL	LIBERTADOR GENERAL BERNARDO O'HIGGINS			668	5445	SI	NO	
CIENCIAS RELIGIOSAS Y FILOSOFICAS	54245	MUNICIPAL	MAULE			570	5325	NO	NO	
CIENCIAS DE LA SALUD	65405	MUNICIPAL	MAULE			698	5665	SI	SI	
CIENCIAS DE LA SALUD	61335	PARTICULAR SUBVENCIONADO	MAULE			605	5870	NO	NO	
CIENCIAS DE LA SALUD	62465	MUNICIPAL	MAULE			651	5755	SI	NO	
CIENCIAS DE LA SALUD	63320	PARTICULAR SUBVENCIONADO	MAULE			652	5550	SI	SI	




Aplicación de *Pandas Profiling*

Overview	Warnings 6	Reproduction
Warnings		
PACE has constant value "PACE"		Constant
LATITUD has 16651 (100.0%) missing values		Missing
LONGITUD has 16651 (100.0%) missing values		Missing
PACE has 16582 (99.6%) missing values		Missing
LATITUD is an unsupported type, check if it needs cleaning or further analysis		Unsupported
LONGITUD is an unsupported type, check if it needs cleaning or further analysis		Unsupported

Fases de ETL

Transformación

Ejemplo 1 : Desde un set de datos de postulaciones a una universidad, *Pandas Profiling* pudo detectar valores faltantes en las columnas Longitud, Latitud y PACE (Programa de Acceso a la Educación Superior). Consultando al negocio, se decidió eliminar las columnas Longitud y Latitud por no ser relevantes para el problema y la columna PACE si es relevante, por lo que se decidió completar los valores faltantes por “Sin PACE”.



OpenRefine postulaciones.xlsx Permalink

Facet / Filter Undo / Redo 0 / 0

Refresh Reset All Remove All

16651 records

Show as: rows records Show: 5 10 25 50 records


LATITUD change
0 choices Sort by: name count
(blank) 16651
Facet by choice counts

LONGITUD change
0 choices Sort by: name count
(blank) 16651
Facet by choice counts

PACE change
1 choices Sort by: name count
PACE 89
(blank) 16582
Facet by choice counts

LATITUD	LONGITUD	PTJE_NEM	PSU_PROMLM	PACE	GRATUIDAD	MATRICULADO
		431	5155		NO	NO
		445	5320		NO	NO
		620	5510		NO	NO
		672	5940	PACE	SI	SI
		672	4775		NO	NO
		775	5715		NO	NO
		688	5530		NO	NO
		637	5420		NO	NO
		657	5635		NO	NO

Aplicación de *OpenRefine*



OpenRefine postulaciones.xlsx Permalink

text transform on 16673 cells in column PACE:
grel:if(value==null,'SIN PACE',value) Undo

Facet / Filter Undo / Redo 3 / 3

Refresh Reset All Remove All

16651 records

Show as: rows records Show: 5 10 25 50 records

LATITUD change
No column named LATITUD

LONGITUD change
No column named LONGITUD

PACE change
2 choices Sort by: name count
PACE 89
SIN PACE 16673
Facet by choice counts

PTJE_NEM	PSU_PROMLM	PACE	GRATUIDAD	MATRICULADO
431	5155	SIN PACE	NO	NO
445	5320	SIN PACE	NO	NO
620	5510	SIN PACE	NO	NO
672	5940	PACE	SI	SI
672	4775	SIN PACE	NO	NO
775	5715	SIN PACE	NO	NO
688	5530	SIN PACE	NO	NO





Fases de ETL

Transformación

Ejemplo 2 : Desde el mismo set de datos de postulaciones de la universidad, desde el reporte de *Pandas Profiling* se pudo detectar valores anómalos en las columnas PUNTAJE y PSU_PROMLM, dado que no están en un rango de representación real de un puntaje obtenido en la PSU.

FACULTAD	PUNTAJE	GRUPO_DEPEN	REGION	LATITUD	LONGITUD	PTJE_NEM	PSU_PROMLM
CIENCIAS RELIGIOSAS Y FILOSOFICAS	50740	MUNICIPAL	MAULE			431	5155
CIENCIAS RELIGIOSAS Y FILOSOFICAS	50320	MUNICIPAL	LIBERTADOR GENERAL BERNARDO O'HIGGINS			445	5320
CIENCIAS DE LA SALUD	61110	MUNICIPAL	MAULE			620	5510
CIENCIAS DE LA SALUD	65585	PARTICULAR SUBVENCIONADO	MAULE			672	5940
CIENCIAS DE LA SALUD	60950	MUNICIPAL	LIBERTADOR GENERAL BERNARDO O'HIGGINS			672	4775
CIENCIAS DE LA SALUD	69335	MUNICIPAL	REGION METROPOLITANA DE SANTIAGO			775	5715
CIENCIAS DE LA SALUD	62080	PARTICULAR SUBVENCIONADO	MAULE			688	5530
CIENCIAS DE LA SALUD	62110	MUNICIPAL	MAULE			637	5420
CIENCIAS DE LA SALUD	61310	MUNICIPAL	MAULE			657	5635
CIENCIAS DE LA SALUD	62065	PARTICULAR PAGADO	LIBERTADOR GENERAL BERNARDO O'HIGGINS			605	6490
CIENCIAS RELIGIOSAS Y FILOSOFICAS	50230	MUNICIPAL	MAULE			461	5110
CIENCIAS DE LA SALUD	61600	PARTICULAR SUBVENCIONADO	MAULE			605	5775
CIENCIAS RELIGIOSAS Y FILOSOFICAS	56645	MUNICIPAL	LIBERTADOR GENERAL BERNARDO O'HIGGINS			558	5750
CIENCIAS RELIGIOSAS Y FILOSOFICAS	60560	MUNICIPAL	MAULE			642	5395
CIENCIAS DE LA SALUD	62470	MUNICIPAL	BÍO-BÍO			641	5770
CIENCIAS RELIGIOSAS Y FILOSOFICAS	55145	PARTICULAR SUBVENCIONADO	MAULE			566	5105



Aplicación de *Pandas Profiling*

Fases de ETL

Transformación

Ejemplo 2 : Desde el mismo set de datos de postulaciones de la universidad, desde el reporte de *Pandas Profiling* se pudo detectar valores anómalos en las columnas PUNTAJE y PSU_PROMLM, dado que no están en un rango de representación real de un puntaje obtenido en la PSU.



Text transform on 16651 cells in column PUNTAJE:
grel:value/100 [Undo](#)

Text transform on 1 cells in column PSU_PROMLM:
grel:value/10 [Undo](#)



PUNTAJE	GRUPO_DEPEN	REGION	PTJE_NEM	PSU_PROMLM
507	MUNICIPAL	MAULE	431	515
503	MUNICIPAL	LIBERTADOR GENERAL BERNARDO O'HIGGINS	445	532
611	MUNICIPAL	MAULE	620	551
655	PARTICULAR SUBVENCIONADO	MAULE	672	594
609	MUNICIPAL	LIBERTADOR GENERAL BERNARDO O'HIGGINS	672	477
693	MUNICIPAL	REGIÓN METROPOLITANA DE SANTIAGO	775	571
620	PARTICULAR SUBVENCIONADO	MAULE	688	553




Aplicación de *OpenRefine*

Fases de ETL

Transformación

Ejemplo 3 : Analizando los datos del seguimiento del Covid-19 y sus consecuencias en pacientes que lo han padecido, desde el reporte de *Pandas Profiling* se pudo detectar valores anómalos en la columna *Outcome* que determina el resultado final. Particularmente, se observa que para un mismo resultado se tienen valores escritos de distintas maneras, por ejemplo, *death* con *died* para determinar el fallecimiento del paciente, y *discharge* con *discharged* para descartar la enfermedad.



Aplicación de *Pandas Profiling*

Value	Count	Frequency (%)
discharge	95	0.4%
stable	78	0.4%
discharged	42	0.2%
died	21	0.1%
death	14	0.1%
recovered	3	< 0.1%
released from quarantine	3	< 0.1%
Discharged	2	< 0.1%

Fases de ETL

Transformación

Ejemplo 3 : Analizando los datos del seguimiento del Covid-19 y sus consecuencias en pacientes que lo han padecido, desde el reporte de *Pandas Profiling* se pudo detectar valores anómalos en la columna *Outcome* que determina el resultado final. Particularmente, se observa que para un mismo resultado se tienen valores escritos de distintas maneras, por ejemplo, *death* con *died* para determinar el fallecimiento del paciente y *discharge* con *discharged* para descartar la enfermedad.



source	sequence_avail	outcome
http://news.xmnn.cn/xmnn/2020/01/22/100656796.shtml and https://m.weibo.cn/status/4464259805726673?		discharged
(1) https://baijiahao.baidu.com/s?id=1657052519295481709&wfr=spider&for=pc; (2) http://wsjkw.cq.gov.cn/tzgg/20200121/249730.html		discharged
(a) http://www.fcgs.gov.cn/vjw/zwgk/202001/20200125_93696.html (b) http://www.fcgs.gov.cn/vjw/dbxx/202001/20200128_93937.html		discharge
http://wsjkw.hlj.gov.cn/index.php/Home/Zwgk/show/newsid/7699/navid/42/id/3		died
https://www.hongkongfp.com/2020/01/22/breaking-first-case-sars-like-virus-hong-kong-source/		died

Text transform on 14 cells in column outcome:
grel:value.replace('death','died') Undo

Text transform on 137 cells in column outcome:
grel:value.replace('discharge','discharged')
value.replace('Discharged','discharged') Undo

Aplicación de *OpenRefine*



source	sequence_avail	outcome
(a) http://www.fcgs.gov.cn/vjw/zwgk/202001/20200125_93696.html (b) http://www.fcgs.gov.cn/vjw/dbxx/202001/20200128_93937.html		discharged
http://wsjkw.hlj.gov.cn/index.php/Home/Zwgk/show/newsid/7699/navid/42/id/3		died
https://www.hongkongfp.com/2020/01/22/breaking-first-case-sars-like-virus-hong-kong-source/		died
https://www.eurosurveillance.org/content/10.2807/1560-7917.ES.2020.25.6.2000094		discharged
https://www.eurosurveillance.org/content/10.2807/1560-7917.ES.2020.25.6.2000094		discharged



Fases de ETL

Transformación

Ejemplo 4 : El Gerente de Ventas de una compañía solicitó el reporte de los 20 mejores clientes según el monto total de las compras que han realizado. Al explorar los datos desde la base de datos OLTP, el Gerente planteó dos requisitos específicos de transformación para ser considerados en su reporte de analítica :

Requisito 1 : El nombre del cliente debe aparecer completo en una sola columna

Requisito 2 : El sexo del cliente debe aparecer de manera más descriptiva, "Masculino" en vez de "M" y "Femenino" en vez de "F".

20 rows

Show as: rows records Show: 5 10 25 50 rows

			▼ All	▼ NOMBRE	▼ APELLIDO	▼ EMAIL	▼ SEXO	▼ SumaDeTOTAL
☆	🗨	1.		Kai	Correia	KaiCostaCorreia@superrito.com	M	561772
☆	🗨	2.		Kauã	Lima	KauaGomesLima@fleckens.hu	M	418351
☆	🗨	3.		Felipe	Barbosa	FelipeSousaBarbosa@armyspy.com	M	406256
☆	🗨	4.		Camila	Santos	CamilaCardosoSantos@teleworm.us	F	405573
☆	🗨	5.		Lucas	Almeida	LucasLimaAlmeida@superrito.com	M	402818
☆	🗨	6.		Carlos	Rocha	CarlosGomesRocha@supermail.com	M	400563
☆	🗨	7.		Clara	Cunha	ClaraBarrosCunha@teleworm.us	F	391682
☆	🗨	8.		Kauã	Castro	KauaSantosCastro@jourrapide.com	M	390308
☆	🗨	9.		Paulo	Dias	PauloAlmeidaDias@superrito.com	M	384346
☆	🗨	10.		Martim	Oliveira	MartimCastroOliveira@armyspy.com	M	382303

Fases de ETL

Transformación

Ejemplo 4 : El Gerente de Ventas de una compañía solicitó el reporte de los 20 mejores clientes en términos de monto total que han adquirido. Al explorar los datos desde la base de datos OLTP, el Gerente planteó dos requisitos específicos de transformación para ser considerados en su reporte de analítica :

Requisito 1 : El nombre del cliente debe aparecer completo en una sola columna



Aplicación de *OpenRefine*

Requisito 2 : El sexo del cliente debe aparecer de manera más descriptiva, "Masculino" en vez de "M" y "Femenino" en vez de "F".



Facet / Filter

Undo / Redo 5 / 5

Refresh

Reset All

Remove All

NOMBRE COMPLETO

change

20 choices

Sort by: name count

Cluster

Anna Oliveira 1

Camila Santos 1

Carlos Rocha 1

SEXO

change

2 choices

Sort by: name count

Cluster

Femenino 6

Masculino 14

20 rows

Show as: rows records

Show: 5 10 25 50 rows

		NOMBRE COMP	EMAIL	SEXO	SumaDeTOTAL
1.	Kai Correia	KaiCostaCorreia@superrito.com	Masculino	561772	
2.	Kauã Lima	KauaGomesLima@fleckens.hu	Masculino	418351	
3.	Felipe Barbosa	FelipeSousaBarbosa@armyspy.com	Masculino	406256	
4.	Camila Santos	CamilaCardosoSantos@teleworm.us	Femenino	405573	
5.	Lucas Almeida	LucasLimaAlmeida@superrito.com	Masculino	402818	
6.	Carlos Rocha	CarlosGomesRocha@supermail.com	Masculino	400563	
7.	Clara Cunha	ClaraBarrosCunha@teleworm.us	Femenino	391682	
8.	Kauã Castro	KauaSantosCastro@jourrapide.com	Masculino	390308	
9.	Paulo Dias	PauloAlmeidaDias@superrito.com	Masculino	384346	
10.	Martim Oliveira	MartimCastroOliveira@armyspy.com	Masculino	382303	

Consideraciones




i1 Cosa !

¿Qué es importante recordar sobre análisis exploratorio de datos (EDA)?

PREGUNTAS


Fases de ETL

Carga : Los datos consiste en mover (o transportar) los datos desde las fuentes operacionales o el almacenamiento intermedio hasta el DW y cargar los datos en las correspondientes estructuras de datos.



Fases de ETL

Carga : En la carga inicial se mueven grandes volúmenes de datos, y en los mantenimientos periódicos (*refresh*) se mueven pequeños volúmenes de datos.



- La frecuencia del *refresh* está determinada por la granularidad del DW y los requisitos de los usuarios.

Fases de ETL

Carga : Algunas técnicas de *refresh* son :

Extracción total desde las fuentes. Este es un método más costoso.

Técnicas incrementales, como la detección y propagación de los cambios sobre las tablas base mediante *triggers*.

Fases de ETL

Carga : Consideraciones a tener en cuenta :

Desactivar Indices antes de cargar datos y después volver a recrear

Considerar no manejar constraints

Inserciones por lotes o bulk insert



INF330

Inteligencia de Negocios

Profesor Mauricio Figueroa Colarte

Segundo Semestre 2026



UNIVERSIDAD TECNICA
FEDERICO SANTA MARIA



Departamento de Informática
Universidad Técnica Federico Santa María