

INF330

Perfilamiento antes de la primera carga

Caso práctico: VENTAS_OLTP con datos y VENTAS_DW vacío

Profesor Mauricio Figueroa Colarte · Segundo Semestre 2026



UNIVERSIDAD TECNICA
FEDERICO SANTA MARIA



Departamento de Informática
Universidad Técnica Federico Santa María

Escenario de trabajo

1 VENTAS_OLTP


La fuente ya contiene clientes, productos, facturas e items. El perfilamiento se ejecuta con consultas de lectura y conserva evidencia de cada hallazgo.

2 VENTAS_DW


El esquema dimensional ya existe. Todas las tablas parten con cero filas. El modelo define el destino, pero todavía faltan reglas de transformación y controles de carga.

Resultado de la sesión: matriz fuente-destino, decisiones de calidad, secuencia de carga y pruebas de aceptación.

VENTAS_OLTP




VENTAS_DW



1 · Perfilamiento antes del ETL

Después de Kimball: validar antes de construir



El modelo define el destino. El perfilamiento establece las reglas que deben cumplirse antes de insertar la primera fila.

EDA y perfilamiento en una OLTP

1 Estructura

Tipos, longitudes, nulabilidad, precisión y compatibilidad con el destino.

2 Contenido

Nulos, dominios, rangos, formatos, extremos y valores improbables.

3 Relaciones

Claves huérfanas, cardinalidad, duplicados y cobertura de joins.

4 Operación

Volumen, fechas, cambios, ventana de extracción e impacto en la OLTP.

Salida del EDA: contrato de datos + decisiones + consultas que luego serán pruebas de la ETL.

Procedimiento repetible: de la pregunta a la regla

1 Elegir objeto

Una dimensión o un proceso de negocio.

2 Declarar grano

Una fila representa... y su clave de negocio es...

3 Trazar fuente

Tablas, columnas, joins y filtros necesarios.

4 Perfilar

Ejecutar consultas y guardar resultados.

5 Interpretar

Validar la semántica con el negocio.

6 Convertir

Regla ETL + rechazo + auditoría + prueba.

La consulta entrega evidencia. La regla de ETL requiere una decisión explícita.

2 · Caso VENTAS

Línea base antes de la ETL

VENTAS_OLTP · inventario fuente


Objeto	Filas
CLIENTE	1.008
DIRECCION	1.007
FACTURA	25.400
ITEM_FACTURA	35.762
PRODUCTO	233

VENTAS_DW · estado inicial

Objeto	Filas iniciales
DIM_CLIENTE	0
DIM_PRODUCTO	0
DIM_FACTURA	0
DIM_TIEMPO	0
HECHOS	0

Los ceros fijan la línea base. Los conteos esperados del DW se definen después de decidir reglas, rechazos y exclusiones.

Mapa de fuentes, reglas y destinos



Cada flecha representa hipótesis que deben verificarse antes de codificar.

3 · Perfilamiento guiado

Prueba 1 · Compatibilidad estructural

SQL SERVER 2019

```
SELECT MAX(LEN(EMAIL)) AS max_email  
FROM dbo.CLIENTE;
```

```
SELECT MAX(LEN(FORMA)) AS max_forma  
FROM dbo.FORMA_PAGO;
```

Atributo	Origen	Destino	Máx. observado
EMAIL cliente	varchar(60)	varchar(50)	40
FORMA de pago	varchar(50)	varchar(30)	28

Hoy los valores caben; mañana la fuente permite datos que el DW no admite.

- **Decisión:** alinear longitudes o validar antes de insertar.
- **Nunca:** permitir truncamiento silencioso.
- **Prueba:** contar valores que exceden el contrato destino.

Prueba 2 · Cobertura del join

SQL SERVER 2019

```
SELECT c.IDCLIENTE, c.NOMBRE, c.APELLIDO  
FROM dbo.CLIENTE AS c  
LEFT JOIN dbo.DIRECCION AS d  
  ON d.ID_CLIENTE = c.IDCLIENTE  
WHERE d.IDDIRECCION IS NULL;
```

Resultado del caso

1

cliente sin dirección

IDCLIENTE 1002 · Mario Soares

0

facturas asociadas

No afecta hechos actuales

La vista CLIENTES_DW usa INNER JOIN: este cliente desaparece del conjunto de extracción.

- Elegir explícitamente: completar, usar “Desconocido” o rechazar.
- Registrar la disposición de cada ID de origen.
- No confundir “sin ventas” con “problema resuelto”.

Prueba 3 · Unicidad de la clave de negocio

SQL SERVER 2019

```
SELECT EMAIL, COUNT(*) AS filas  
FROM dbo.CLIENTE  
GROUP BY EMAIL  
HAVING COUNT(*) > 1;
```

7

filas con el mismo email

carlos.perez@example.com

7

IDCLIENTE distintos

2009, 2010, 2011, 2013, 2015, 2017 y 2020

La PK técnica es única; la identidad de negocio parece repetida.

Los siete registros no tienen facturas; eso explica su bajo impacto actual, no autoriza eliminarlos.

- **Antes de deduplicar:** definir la clave de negocio aprobada.
- **Luego:** elegir supervivencia, consolidación o conservación con marca.
- **Control:** ningún ID puede desaparecer sin una disposición auditable.

4 · Granularidad y medidas

Prueba 4 · Declarar y comprobar el grano

SQL SERVER 2019

```
SELECT COUNT(*) AS filas,  
       COUNT(DISTINCT ID_ITEMFACTURA) AS items  
FROM dbo.ITEM_FACTURA;
```

Declaración de grano

Una fila de HECHOS debe representar una línea de una factura.

35.762

filas de detalle

Una por ID_ITEMFACTURA

35.762

ID_ITEMFACTURA distintos

La PK sostiene el grano fuente

- (ID_FACTURA, ID_PRODUCTO) no es una clave: se repite en 66 combinaciones.
- Conservar ID_ITEMFACTURA en staging/auditoría facilita reconciliar.
- El grano debe fijarse antes de buscar o eliminar duplicados.

Prueba 5 - Repeticiones del detalle

SQL SERVER 2019

```
SELECT ID_FACTURA, ID_PRODUCTO,  
       CANTIDAD, TOTAL, COUNT(*) AS filas  
FROM dbo.ITEM_FACTURA  
GROUP BY ID_FACTURA, ID_PRODUCTO,  
         CANTIDAD, TOTAL  
HAVING COUNT(*) > 1;
```

66

pares factura-producto repetidos

Pueden representar líneas
válidas

17

grupos exactamente iguales

Misma factura, producto, cantidad y
total

Ni siquiera un par exacto demuestra por sí solo que una fila sea errónea.

- Cargar por ID_ITEMFACTURA. Evitar DISTINCT como regla implícita.
- Si el negocio confirma duplicación, registrar clave, criterio y supervivencia.
- Como mínimo, marcar o enviar casos sospechosos a revisión.

Prueba 6 · Validar medidas con su semántica

Control A · Cabecera vs. detalle

CONTROL DE SUMA

- Comparar FACTURA.TOTAL con
- SUM(ITEM_FACTURA.TOTAL) por factura
- Tolerancia sugerida: 0,01

0

facturas con diferencia

25.400 facturas conciliadas

Control B · Precio maestro actual

CONTROL DE SEMÁNTICA

```
SELECT COUNT(*) AS alertas
FROM dbo.ITEM_FACTURA i
JOIN dbo.PRODUCTO p
  ON p.IDPRODUCTO = i.ID_PRODUCTO
WHERE ABS(i.TOTAL - i.CANTIDAD*p.VALOR) > .01;
```

149

alertas encontradas

No equivalen automáticamente a
errores

El TOTAL transaccional puede reflejar precio histórico o descuento; no debe reemplazarse por el precio maestro actual.

Prueba 7 · Integridad referencial y preparación temporal

Integridad observada

0

FK huérfanas

Cadena transaccional principal

0

facturas sin items

Todas tienen detalle

3

vendedores sin gerente

Posibles raíces válidas

2015-2017

rango de fechas de venta

01-01-2015 a 27-12-2017

Incrementalidad

La OLTP no contiene fecha_modificacion ni otra marca confiable de cambio.

- FECHA de factura detecta ventas nuevas, no cambios tardíos en clientes o productos.
- Para una demostración: carga completa o snapshot con hash y auditoría.
- Para producción: evaluar CDC, Change Tracking o columna last_modified confiable.
- Toda estrategia incremental necesita watermark, solapamiento y reejecución idempotente.

Un NULL puede ser válido: ID_GERENTE nulo puede representar la cima de la jerarquía.

5 · De la evidencia al diseño ETL

Decisiones que deben existir antes de cargar

Destino	Decisiones previas	Controles previstos
DIM_CLIENTE	Clave de negocio, política para dirección faltante, deduplicación aprobada y miembro Desconocido	Cada ID origen tiene disposición y linaje
DIM_PRODUCTO	IDPRODUCTO como clave de negocio, atributos que disparan cambio y estrategia SCD tipo 2	Una sola versión vigente y periodos sin solaparse
DIM_TIEMPO y catálogos	Rango de fechas, dominios válidos, claves reservadas y orden de carga	Toda FK puede resolverse antes de HECHOS
HECHOS	Grano por ID_ITEMFACTURA, medidas transaccionales, tratamiento de repetidos y rechazos	0 claves sin resolver y conciliación de filas y montos

Una prueba futura debe acompañar cada decisión. La ETL no debería contener reglas que solo existen en la memoria del desarrollador.

Reglas y pruebas derivadas del perfilamiento

Hallazgo	Regla antes de programar	Prueba de aceptación
Origen admite textos más largos	Validar longitud o alinear el contrato del DW	0 truncamientos. Todo excedente queda rechazado
Cliente sin dirección	LEFT JOIN y disposición aprobada: completar, Desconocido o rechazo	Fuente = cargados + rechazados + excluidos
Identidad repetida	Clave de negocio y supervivencia aprobadas con linaje	Unicidad según la regla y trazabilidad de cada ID
Líneas de factura repetidas	Cargar por ID_ITEMFACTURA y conservar todas salvo regla aprobada	Las 35.762 líneas tienen una disposición
Sin marca confiable de cambio	Carga completa controlada o mecanismo CDC/CT	Reejecución idempotente y watermark o hash auditable

Las consultas de perfilamiento se reutilizan como controles automáticos de la ejecución.

Secuencia de la primera carga controlada

Paso	Actividad	Condición de salida
1 · Staging con LOTE_ID	Extraer un snapshot y registrar fecha, origen, parámetros y conteos	Extracción cerrada y auditable
2 · Miembros desconocidos	Crear claves sustitutas reservadas para faltantes válidos	Claves disponibles antes de resolver FK
3 · Dimensiones	Aplicar claves de negocio, SCD, valores por defecto y rechazos	Una fila vigente por clave de negocio
4 · HECHOS	Resolver claves sustitutas y cargar una fila por ID_ITEMFACTURA	0 claves sustitutas sin resolver
5 · Reconciliar y publicar	Comparar filas, montos, rechazos y estado del lote	Solo un lote aprobado queda disponible

Si falla un control, el lote conserva su evidencia y queda en estado RECHAZADO. La corrección se prueba con una reejecución.

Criterios de aceptación de la primera carga

Control	Resultado esperado
Disposición de clientes	1.008 = cargados + rechazados + excluidos por regla documentada
Disposición del detalle	35.762 = filas de HECHOS + rechazadas + excluidas por regla documentada
Claves sustitutas	0 claves sin resolver en HECHOS
Tipos y longitudes	0 truncamientos y 0 conversiones silenciosas
Montos	Suma de TOTAL_ITEM = suma de ITEM_FACTURA.TOTAL aceptados, dentro de la tolerancia
Reejecución	El mismo lote agrega 0 duplicados y produce el mismo resultado

Bitácora mínima del lote

LOTE_ID · inicio · fin · origen · filas leídas · filas cargadas · filas rechazadas · estado · watermark o hash

Puerta de entrada a la primera carga

1 Contrato

- ❑ Grano declarado
- ❑ Claves de negocio
- ❑ Mapeo fuente-destino
- ❑ Tipos y longitudes
- ❑ SCD y miembros desconocidos

2 Calidad

- ❑ Nulos interpretados
- ❑ Duplicados investigados
- ❑ Huérfanos medidos
- ❑ Dominios y rangos
- ❑ Medidas reconciliadas

3 Operación

- ❑ Estrategia incremental
- ❑ Idempotencia
- ❑ Rechazos y auditoría
- ❑ Conteos de control
- ❑ Criterios de aceptación

La carga puede comenzar cuando cada supuesto importante tiene una decisión, un responsable y una prueba.

¡1 Cosa !

¿Qué es importante recordar
sobre el perfilamiento de
datos?

PREGUNTAS