

INF330

Perfilamiento de datos antes del diseño ETL

Caso práctico: VENTAS_OLTP → VENTAS_DW
Visual Studio · SSIS Data Profiling Task · Reporte global

Profesor Mauricio Figueroa Colarte · Segundo Semestre 2026




UNIVERSIDAD TECNICA
FEDERICO SANTA MARIA



Departamento de Informática
Universidad Técnica Federico Santa María

Objetivo de la actividad

Antes de construir la ETL, debemos saber cómo vienen los datos y qué riesgos pueden afectar la primera carga del Data Warehouse.



Resultado esperado

- Ejecutar perfiles sobre tablas fuente de VENTAS_OLTP.
- Generar XML por tabla con evidencia técnica.
- Consolidar los XML en un reporte global en Excel.
- Traducir hallazgos en reglas de transformación para la ETL.

Idea central

Perfilamiento $\neq$ ETL
El profiling no corrige datos; entrega evidencia para decidir qué transformar, rechazar o auditar.

Escenario del caso VENTAS

La fuente OLTP contiene datos. El DW conserva el modelo dimensional y se utiliza como contrato de destino para diseñar la ETL.



Tablas fuente priorizadas

Ruta	Tablas OLTP	Destino esperado
Cliente	CLIENTE + DIRECCION	DIM_CLIENTE
Producto	PRODUCTO + CATEGORIA + PROVEEDOR	DIM_PRODUCTO
Venta	FACTURA + ITEM_FACTURA	HECHOS + DIM_TIEMPO
Catálogos	VENDEDOR + FORMA_PAGO	DIM_VENDEDOR + DIM_FORMA

Preparación del entorno

Proyecto entregado

```
VENTAS_OLTP_Profiler.sln
└─ VENTAS_OLTP_Profiler
    ├── 01_Perfil_Cliente.dtsx
    ├── 02_Perfil_Producto.dtsx
    ├── 03_Perfil_Factura.dtsx
    ├── 04_Perfil_ItemFactura.dtsx
    ├── 05_Perfil_Catalogos.dtsx
    └─ Resultados
        └─ *.xml
```

Conexión local

```
Server name: .
Database: VENTAS_OLTP
Authentication: Windows Authentication
Output: .\Resultados\<TABLA>_Profile.xml
```

Regla práctica

- Ejecutar primero 01_Perfil_Cliente.dtsx.
- Confirmar que se generan CLIENTE_Profile.xml y DIRECCION_Profile.xml.
- Abrir el XML en Data Profile Viewer para interpretar la evidencia.
- Repetir el patrón en los demás paquetes.

Visual Studio: abrir la solución

Abra la solución y verifique que aparezcan los paquetes SSIS en el explorador. La primera actividad se realiza sobre 01_Perfil_Cliente.dtsx.

The screenshot displays the Visual Studio 2019 interface for the 'VENTAS_OLTP_Profiler' solution. The 'Solution Explorer' on the left shows the project structure with '01_Perfil_Cliente.dtsx' selected. The 'Control Flow' task on the right shows a sequence of two tasks: 'Perfil CLIENTE' and 'Perfil DIRECCION', connected by a green line. A yellow callout box on the right provides instructions: '1. Abra el paquete 01_Perfil_Cliente.dtsx', '2. Verifique Control Flow', and '3. Revise Connection Managers'. The status bar at the bottom indicates the connection managers: 'VENTAS_OLTP | CLIENTE_Profile.xml | DIRECCION_Profile.xml'.

Visual Studio 2019 · VENTAS_OLTP_Profiler

File Edit View Project SSIS Debug

Solution Explorer

- ▼ VENTAS_OLTP_Profiler
 - ▼ SSIS Packages
 - 01_Perfil_Cliente.dtsx
 - 02_Perfil_Producto.dtsx
 - 03_Perfil_Factura.dtsx
 - 04_Perfil_ItemFactura.dtsx
 - 05_Perfil_Catalogos.dtsx

Control Flow


Perfil CLIENTE

Perfil DIRECCION

1. Abra el paquete 01_Perfil_Cliente.dtsx
2. Verifique Control Flow
3. Revise Connection Managers

Connection Managers: VENTAS_OLTP | CLIENTE_Profile.xml | DIRECCION_Profile.xml

Paso 1 · Revisar el Control Flow




Qué debe observar el estudiante

- Ambas tareas están en la pestaña Control Flow.
- No se usa Data Flow: el profiling es una tarea de control.
- Cada tarea escribe su propio XML de salida.
- La flecha verde permite ejecutar ambas tareas en secuencia.

Resultado esperado:
Resultados\CLIENTE_Profile.xml
Resultados\DIRECCION_Profile.xml

Paso 2 · Verificar la conexión VENTAS_OLTP




Propiedades de conexión

```
Data Source=.  
Initial Catalog=VENTAS_OLTP  
Integrated Security=True
```

Prueba antes de ejecutar

- La base VENTAS_OLTP debe existir en la instancia local.
- El usuario de Windows debe tener permisos de lectura.
- La carpeta Resultados debe existir dentro del proyecto.

Paso 3 · Configurar el destino XML



En Perfil CLIENTE

```
DestinationType = FileConnection
Destination = CLIENTE_Profile.xml
OverwriteDestination = True
```

En Perfil DIRECCION

```
DestinationType = FileConnection
Destination = DIRECCION_Profile.xml
OverwriteDestination = True
```

Si aparece `DirectoryNotFoundException`, revise que la carpeta Resultados exista y que el XML apunte a una ruta válida.

Paso 4 · Crear el perfil de dbo.CLIENTE

Data Profiling Task Editor

General

Profile Requests

Quick Profile · dbo.CLIENTE

Connection Manager

VENTAS_OLTP

Table or View

dbo.CLIENTE

Requests

Null Ratio · Statistics · Length · Value · Pattern · Candidate Key

Quick Profile..

Perfiles recomendados

Perfil	Uso en ETL
Null Ratio	faltantes
Statistics	rangos
Value Distribution	dominios
Length Distribution	longitudes
Pattern	formatos
Candidate Key	unicidad

En la demostración se aplica a todas las columnas para que los estudiantes observen una lectura completa de la tabla.

INF330 | Inteligencia de Negocios

Profesor Mauricio Figueroa Colarte

9

Paso 5 · Agregar DIRECCION y ejecutar

Data Profiling Task Editor

General

Profile Requests

Quick Profile · dbo.DIRECCION

Connection Manager: VENTAS_OLTP

Table or View: dbo.DIRECCION

Requests: Null Ratio · Statistics · Length · Value · Pattern · Candidate Key

Quick Profile..

Ejecutar el paquete

- Guardar cambios en el paquete.
- Presionar F5 o Start Debugging.
- Confirmar que ambas tareas quedan en verde.
- Abrir los XML generados desde Resultados.

Criterio de éxito
CLIENTE_Profile.xml y DIRECCION_Profile.xml
existen y se abren en Data Profile Viewer.

Lectura en Data Profile Viewer

El visor permite inspeccionar el XML: nulos, estadísticas, distribuciones, patrones y claves candidatas. La lectura técnica se transforma después en reglas ETL.

Data Profile Viewer · CLIENTE_Profile.xml

Profiles

- Column Null Ratio
 - CLIENTE.IDCLIENTE
 - CLIENTE.NOMBRE
 - CLIENTE.EMAIL
- Candidate Key
 - CLIENTE.IDCLIENTE
 - CLIENTE.EMAIL
- Value Distribution
 - CLIENTE.SEXO

Columna	Nulos	Lectura
EMAIL	0	sin faltantes
SEXO	0	dominio controlado
IDCLIENTE	0	clave exacta

IDCLIENTE = clave exacta
EMAIL ≈ clave casi-candidata
SEXO: M=606, F=402

Conversión didáctica

- No basta mirar el valor técnico.
- Cada hallazgo debe producir una decisión.
- La decisión debe poder verificarse en la carga del DW.

Hallazgo → Riesgo DW → Regla ETL → Prueba de carga

11

INF330 | Inteligencia de Negocios

Profesor Mauricio Figueroa Colarte

Lineamientos para completar el ejercicio

Luego de completar 01_Perfil_Cliente.dtsx, los demás paquetes repiten el mismo patrón: tabla fuente, XML de salida, perfiles y lectura ETL.

Paquete	Tablas	Foco del análisis
02_Perfil_Producto	PRODUCTO · CATEGORIA · PROVEEDOR	costos, valores, catálogos, claves
03_Perfil_Factura	FACTURA	fechas, total, cliente, vendedor, forma de pago
04_Perfil_ItemFactura	ITEM_FACTURA	grano de HECHOS, cantidad, total, producto
05_Perfil_Catalogos	VENDEDOR · FORMA_PAGO	dominios, jerarquía gerente, catálogos

Entregable por cada grupo de tablas


- XML generado correctamente.
- Captura o evidencia del visor.
- Hallazgos relevantes documentados.
- Regla ETL propuesta para cada riesgo.

No perfilar por perfilar

El objetivo no es “tener XML”. El objetivo es evitar errores de carga y diseñar transformaciones antes de insertar datos en el DW.

Flujo completo del proyecto SSIS

Vista global del ejercicio: cinco paquetes, nueve tablas perfiladas y salidas XML consolidadas para el reporte global.



Del XML al reporte global

Los XML son la evidencia detallada. El Excel consolida la lectura para la toma de decisiones del diseño ETL.

VENTAS_OLTP_Perfilamiento.xlsx

Tabla	Filas	Columnas	Nulos	Clave exacta
CLIENTE	1008	6	0	IDCLIENTE
DIRECCION	1007	6	0	IDDIRECCION
PRODUCTO	233	6	0	IDPRODUCTO
CATEGORIA	9	2	0	IDCATEGORIA
PROVEEDOR	41	2	0	IDPROVEEDOR
FACTURA	25400	6	0	IDFACTURA

Resumen

Columnas

Claves

Valores

Patrones

Hallazgos_ETL

Lectura de la hoja Hallazgos_ETL

El reporte separa evidencia técnica de interpretación pedagógica: riesgo DW, regla ETL sugerida y prueba de aceptación.

Resumen del perfilamiento global

9

Tablas

63.510

Filas perfiladas

40

Columnas

3

Nulos detectados


15

Claves exactas

Tabla	Filas	Columnas	Nulos	Clave exacta principal
CLIENTE	1.008	6	0	IDCLIENTE
DIRECCION	1.007	6	0	IDDIRECCION
PRODUCTO	233	6	0	IDPRODUCTO
CATEGORIA	9	2	0	IDCATEGORIA
PROVEEDOR	41	2	0	IDPROVEEDOR
FACTURA	25.400	6	0	IDFACTURA
ITEM_FACTURA	35.762	5	0	ID_ITEMFACTURA
VENDEDOR	24	5	3	IDVENDEDOR
FORMA_PAGO	26	2	0	IDFORMA

Volumen relativo por tabla

El volumen concentra el riesgo operacional en FACTURA e ITEM_FACTURA. Ahí se valida con mayor cuidado el grano de la tabla de hechos.



Calidad: nulos y claves candidatas

Nulos detectados

VENDEDOR.ID_GERENTE
3 valores NULL de 24 filas

Interpretación ETL

- Un NULL puede ser válido por negocio o puede requerir regla de reemplazo.
- Una clave candidata exacta es evidencia para mapear claves de negocio.
- Una clave casi-candidata no debe usarse sin validar duplicados.

Claves candidatas exactas

Tabla	Clave exacta
CLIENTE	IDCLIENTE
DIRECCION	IDDIRECCION, ID_CLIENTE
PRODUCTO	IDPRODUCTO
CATEGORIA	IDCATEGORIA, NOMBRE
PROVEEDOR	IDPROVEEDOR, NOMBRE
FACTURA	IDFACTURA
ITEM_FACTURA	ID_ITEMFACTURA
VENDEDOR	IDVENDEDOR, NOMBRE, EMAIL
FORMA_PAGO	IDFORMA, FORMA

Ejemplo: CLIENTE.EMAIL tiene fuerza 0,994 → revisar duplicados antes de usarlo como clave natural.

Hallazgos que deben transformarse en reglas ETL

Hallazgo	Riesgo DW	Regla / control sugerido
CLIENTE.EMAIL casi-candidato	duplicados como clave natural	mantener IDCLIENTE como clave de negocio; email como atributo
CLIENTE 1.008 vs DIRECCION 1.007	pérdida por INNER JOIN	anti-join y regla para cliente sin dirección
PRODUCTO.PRODUCTO casi-candidato	nombres comerciales repetidos	clave por IDPRODUCTO; nombre no identifica producto
ITEM_FACTURA 35.762 filas	grano de HECHOS	validar 1 fila origen = 1 fila HECHOS o documentar exclusiones
VENDEDOR.ID_GERENTE con NULL	jerarquía incompleta	tratar gerente desconocido o vendedor raíz

Toda regla ETL debe quedar respaldada por evidencia y por una prueba de aceptación post-carga.

Plantilla mínima para documentar cada hallazgo

1

Pregunta

¿Qué estoy verificando?

2

Evidencia

XML / SQL / conteo observado

3

Impacto

¿Qué puede fallar en el DW?

4

Decisión

Regla ETL aprobada

5

Prueba


Cómo demostrar que la carga quedó correcta

Ejemplo aplicado

Pregunta: ¿todos los clientes tendrán dimensión?
Evidencia: CLIENTE=1.008, DIRECCION=1.007
Impacto: el INNER JOIN puede excluir clientes
Decisión: identificar y tratar clientes sin dirección
Prueba: conteo cargado + rechazado + excluido = fuente

Cierre y trabajo esperado

La ETL no comienza programando. Comienza entendiendo el estado real de los datos.



Para completar el ejercicio

- Ejecutar los cinco paquetes SSIS.
- Abrir y revisar los XML relevantes en Data Profile Viewer.
- Regenerar el reporte global VENTAS_OLTP_Perfilamiento.xlsx.
- Seleccionar al menos 5 hallazgos y proponer reglas ETL verificables.

Entrega de evidencia

```
/Resultados
  CLIENTE_Profile.xml
  DIRECCION_Profile.xml
  ...
  VENTAS_OLTP_Perfilamiento.xlsx
```